

Deep Learning Autoencoders

Gomez, Lucas

Volcovinsky, Bruno

Sartorio, Alan






Ejercicio 1



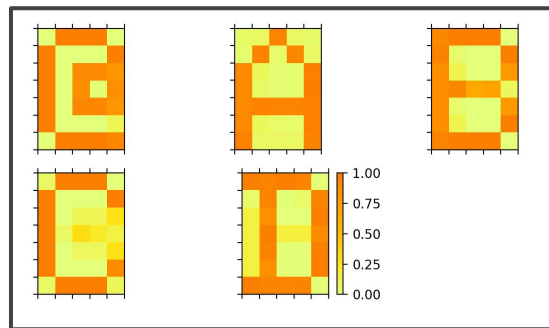



Lista de caracteres




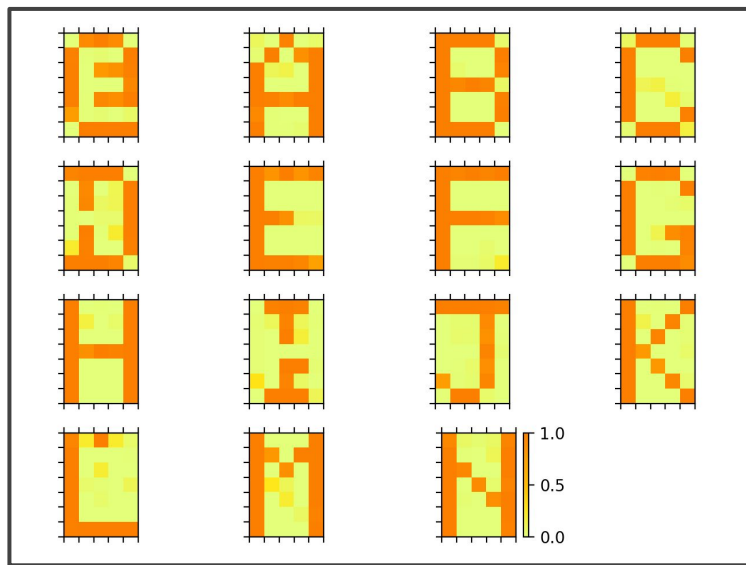
Estructuras de la red



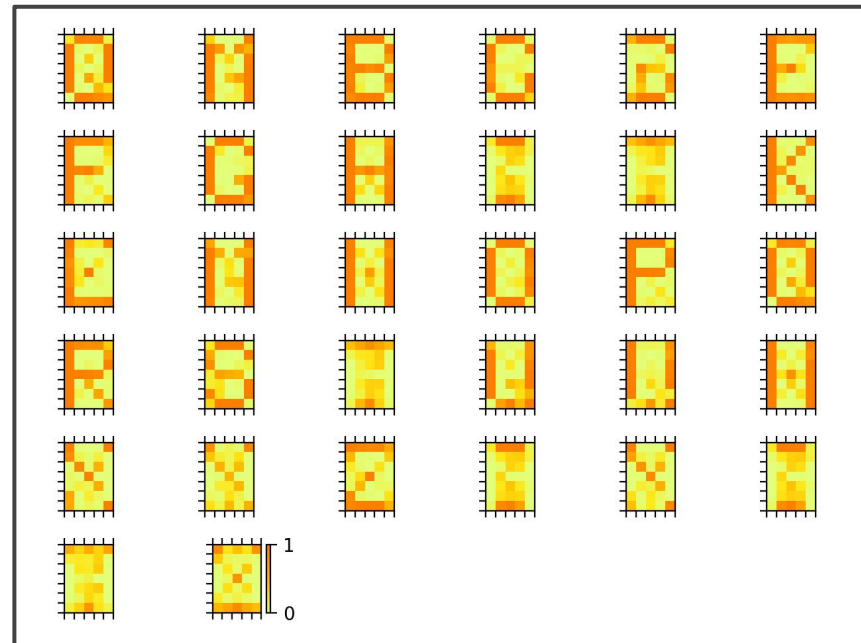

Salidas generadas



Salidas generadas




Salidas generadas







Representación en 2 dimensiones



1 letra




3 letras



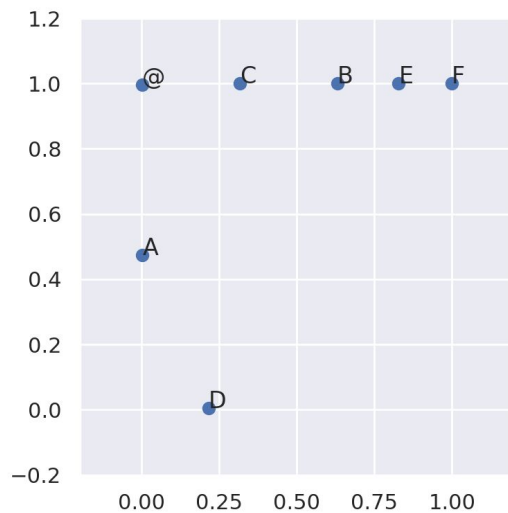
4 letras




Representación en 2 dimensiones



5 letras



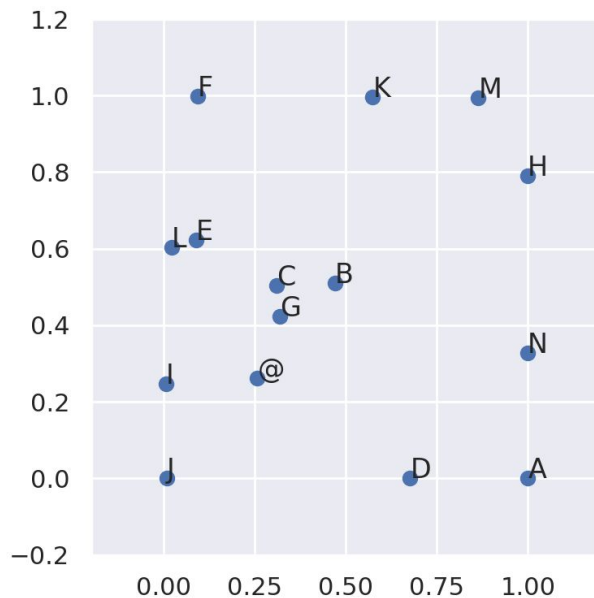
7 letras




11 letras



Representación en 2 dimensiones

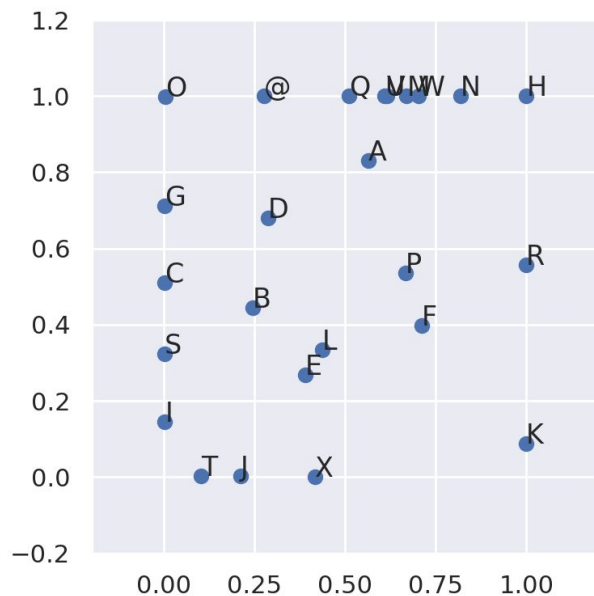


15 letras



20 letras

Representación en 2 dimensiones

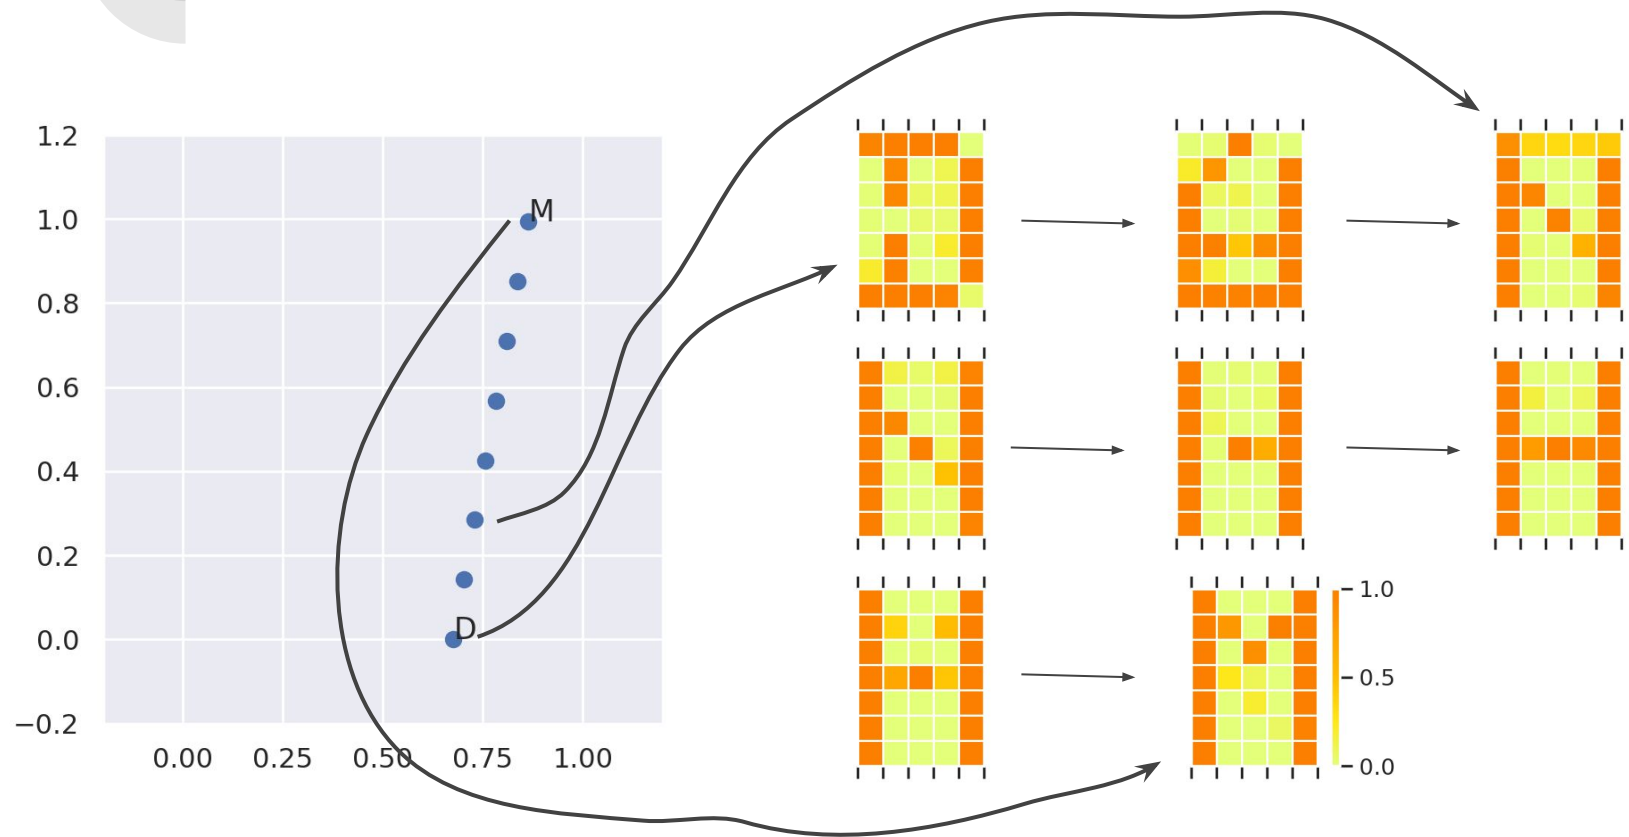


25 letras




32 letras

Nuevas letras




DAE - Estructura de la red




DAE - Capacidad de eliminar ruido

Entrenada
solo con 5
letras



40% de probabilidad de
afectar el pixel

Entrenada con
las 32 letras





Ejercicio 2

Nuevo dataset








Conjunto de datos elegido

50 imágenes


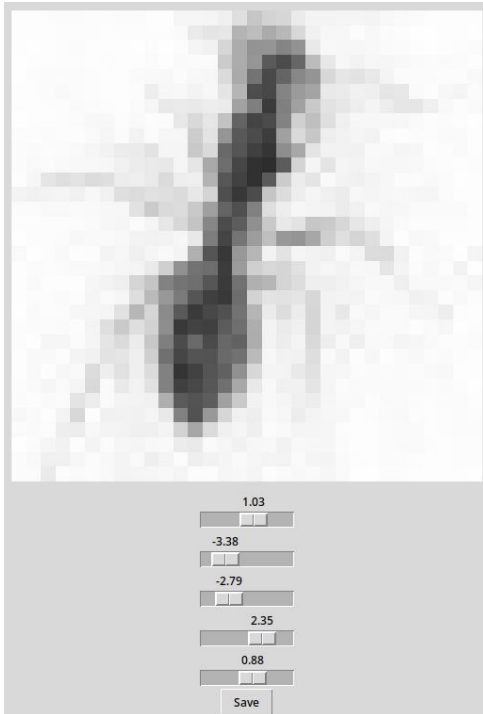




Nuevas muestras generadas



Nuevas muestras generadas





Conclusiones



Conclusiones

- El autoencoder se demoró en realizar el entrenamiento de las fuentes.
- Al agregar capas al autoencoder, se demoraba mucho más en minimizar el error.
- Al variar los valores del espacio latente, podemos generar nuevas salidas.
- La poca cantidad de imágenes del ejercicio 2 nos limitó a la capacidad de generalización de la red.



Muchas gracias